

APRENDIZAJE DE MAQUINA



Hernan Dario Cruz Bueno




DOCENTE:



hernan.cruz@usa.edu.co

PARCIALES





TEMAS

Tipos de Sistemas de ML

Problemas de los sistemas de ML

Ciclo de vida de un proyecto de ML

Regresión Lineal

Regresión Logística

Árboles de Decisión

KNN

Máquinas con vectores de soporte

SVM con kernels

Boosting

Kmeans

Jerarquico

DBscan

MDP

Qlearning

DQlearning



PRUEBA
DIAGNOSTICA

Pide a participantes que
abran

[Joinmyquiz.com](https://joinmyquiz.com)

introduzcan este código

458979



26-2 Machine learning

Grupo de WhatsApp



Modelos Analíticos

¿Qué es un Modelo Analítico?

“Es un proceso que permite combinar datos heterogéneos de muchas fuentes diferentes. Por lo tanto, facilita que distintos tipos de datos sean fusionados para posteriormente poder ser analizados de manera conjunta”.

Existen múltiples definiciones al respecto. Sin embargo, elegimos esta definición para el desarrollo del curso 🤖

Etapas en la creación de Productos Analíticos con Ciencia de Datos



Etapas en la creación de Productos Analíticos con Ciencia de Datos

Este proceso está basado en una metodología estructurada de pasos:



Machine Learning

- Método de análisis de datos que **automatiza la construcción de “Modelos Analíticos”**.
- Rama de la Inteligencia Artificial (AI), basada en la idea de que **los sistemas pueden aprender de datos, identificar patrones y tomar decisiones** con una mínima intervención humana.



Aprender en este contexto quiere decir: identificar patrones complejos en millones de datos 🤖



- **¿El automóvil de conducción autónoma de Google?**

👉 La esencia del Machine Learning.

- **¿Ofertas de recomendación en línea como las de Amazon y Netflix?**

👉 Aplicaciones de ML para la vida diaria.

- **¿Saber lo que los clientes dicen acerca de nosotros en Twitter?**

👉 Machine learning combinado con creación de reglas lingüísticas.

- **¿Detección de fraudes?**

👉 Uno de los usos más importantes en la actualidad del ML.

Importancia

- El interés se debe a los **volúmenes y variedades crecientes de datos disponibles**, el procesamiento computacional más económico y poderoso y el almacenaje de datos asequible y mucho menos costoso.
- Es posible producir modelos de manera rápida y automática que puedan analizar datos grandes y complejos.
- De esta forma, **una organización tiene una mejor oportunidad de identificar oportunidades rentables o de evitar riesgos desconocidos.**

VENTAJAS DE MACHINE LEARNING

Machine Learning



- **Mayor conocimiento** de las necesidades, gustos y hábitos de compra de los clientes.
- **Innovación** en productos y soluciones tecnológicas.
- **Optimización** de la producción y de la productividad.
- Capacidad de realizar **acciones preventivas y correctivas**.
- **Predicción** de tendencias y necesidades.

***¿QUIÉN UTILIZA MACHINE
LEARNING?***

Servicios Financieros

Utilizan la tecnología del aprendizaje basado en máquina para dos fines principales: **identificar insights importantes en los datos y prevenir el fraude.**

Salud

Tendencia en rápido crecimiento en la industria de atención a la salud, gracias a la aparición de dispositivos y sensores que pueden **usar datos para evaluar la salud de un paciente en tiempo real.**

Petróleo y Gas

Principalmente para **encontrar nuevas fuentes de energía, hacer análisis de minerales del suelo, predicción de fallos de sensores de refinerías y optimizar la distribución de petróleo para hacerla más eficiente.**

Gobierno

Dependencias como seguridad pública y los servicios públicos tienen una necesidad particular del ML porque tienen **múltiples fuentes de datos de las que se pueden extraer insights.** Por ejemplo, el análisis de datos en las Smart Cities.

Marketing y Ventas

Los sitios Web que recomiendan artículos que podrían llegar a gustarnos con base en nuestras compras anteriores, utilizan ML para **analizar nuestro historial de compras** y de tal forma promocionar otros artículos que podrían llegar a resultarnos de interés.

Transporte

Analizar datos para identificar patrones y tendencias, es clave para la industria del transporte, que se sustenta en hacer las rutas más eficientes y anticipar problemas potenciales para incrementar la rentabilidad.

¿Qué se requiere para crear buenos sistemas de machine learning?

- Recursos de preparación de datos.
- Algoritmos – básicos y avanzados.
- Automatización y procesos iterativos.
- Escalabilidad del Modelo en producción.



Fases de un proyecto Machine Learning

1

**Definir el
objetivo**

2

**Recolección de
la data**

3

Preparar la data



1 Definir el objetivo

Es vital entender el problema a resolver y cuáles son nuestros objetivos dado las características de la empresa, así como de la data que tendremos a disposición.

Las siguientes preguntas son típicas en esta etapa:

- ¿Qué exactamente deseamos hacer?
- ¿Cómo exactamente podremos hacerlo?
- ¿Es posible lo que deseo dada la data que tengo?

3

Preparar la data

Normalmente lo conocemos como **la limpieza de los datos** o el formateo del dato.

El objetivo de esta etapa es manipular y convertir la data en formas que produzcan mejores resultados. Algunos ejemplos, son:

- Eliminar o inferir datos perdidos, categorizar los valores de las variables, normalizar los valores numéricos o escalarlos para que puedan ser comparables.



Fases de un proyecto Machine Learning





4


Elección del Algoritmo

Una vez que ya hemos preprocesado la data, nos corresponde elegir el algoritmo más adecuado **en relación al problema que deseamos resolver.**

En este punto tenemos que decidir por el **Tipo de Aprendizaje** que vamos a implementar.

4

Elección del Algoritmo



A pair of black-rimmed glasses is placed on a dark surface, likely a desk. The lenses of the glasses reflect the content of a computer monitor in the background. The monitor displays a dark-themed interface with various elements: on the left, a sidebar with blue and white icons; in the center, a large area with colorful data visualizations and charts; on the right, a column of text with syntax-highlighted code in green, yellow, and blue. The overall scene suggests a focus on technology, data science, or programming.

4

Elección del Algoritmo

Aprendizaje Supervisado: son entrenados utilizando ejemplos etiquetados, como una entrada donde se conoce el resultado deseado. El mismo recibe un conjunto de entradas junto con los resultados correctos correspondientes, y el algoritmo aprende comparando su resultado real con resultados correctos para encontrar errores. Luego modifica el modelo en consecuencia es decir, la salida de este algoritmo es conocida.

4

Elección del Algoritmo



Estructura básica de un Algoritmo

A pair of black-rimmed glasses with clear lenses is placed on a dark surface, likely a desk. The lenses reflect the colorful, blurred light of a computer screen in the background. The screen shows various elements: a dark-themed code editor with lines of text in blue, green, and yellow; a sidebar with a tree-like structure; and a main area with some data visualizations or charts. The overall scene is dimly lit, with the primary light source being the computer screen.

4

Elección del Algoritmo

Aprendizaje No Supervisado: Se utiliza contra datos que no tienen etiquetas históricas. **No se da la "respuesta correcta" al sistema.** El objetivo es explorar los datos y encontrar alguna estructura en su interior. Por ejemplo: identificar segmentos de clientes con atributos similares que después puedan ser tratados de manera semejante en campañas de marketing o bien puede encontrar los atributos principales que separan los segmentos de clientes.

A pair of black-rimmed glasses is placed on a dark surface, likely a desk, in front of a computer monitor. The monitor displays a dark-themed code editor with various lines of code in different colors (blue, green, yellow, red). The glasses' lenses reflect the code on the screen. A small green circle with the number '4' is positioned to the left of the glasses.

4

Elección del Algoritmo

Aprendizaje por Refuerzo: el algoritmo descubre a través de ensayo y error qué acciones producen las mayores recompensas. Este tipo de aprendizaje tiene tres componentes principales: el agente (el que aprende o toma decisiones), el entorno (todo con lo que interactúa el agente) y acciones (lo que el agente puede hacer).

Se utiliza a menudo para robótica, juegos y navegación.

Entrenar el modelo

5

Este paso tiene una relación directa con conceptos que abordaremos más adelante en el curso (Training y Test). Sin embargo, el proceso de entrenamiento de un modelo de ML, consiste en proporcionarle al modelo **datos de entrenamiento** de los cuales pueda aprender.





6

Validar el modelo

Se realizará con la data de validación y procederemos a **“correr” el algoritmo y a evaluar los resultados obtenidos.**

En el caso de que los resultados no sean satisfactorios, deberemos volver a la etapa 5 hasta que nuestro modelo se ajuste bien a las dos particiones (data de entrenamiento y data de validación).

Deployment del modelo

Implementación en producción de nuestro modelo. Generalmente, solemos ayudarnos de la nube a través de los 3 vendors más conocidos que existen actualmente: AWS, Azure y GCP.

6



TALLER

Preguntas de Interpretación

"Si ustedes fueran los administradores del refugio, ¿qué acciones tomarían basándose en los resultados de su modelo?"

Ejemplo de respuestas esperadas:

✅ **Si el modelo muestra que animales pequeños se adoptan más rápido:**

- Hacer campañas de adopción específicas para perros grandes.
- Ajustar los espacios y la comida en función del tiempo de estadía.

✅ **Si el análisis de residuales muestra que el modelo no es bueno:**

- Evaluar nuevas variables (por ejemplo, comportamiento del animal).
- Considerar un modelo no lineal

Clave: Deben justificar cómo sus hallazgos pueden mejorar la toma de decisiones en el refugio.





1. Banca y Finanzas 🏦

Aplicación: Detección de fraude, predicción de aprobación de crédito, segmentación de clientes.

Dataset: Kaggle - Credit Card Fraud Detection, LendingClub Loan Data

2. Salud y Medicina 🏥

Aplicación: Diagnóstico de enfermedades, predicción de reingresos hospitalarios.

Dataset: Diabetes Dataset, Breast Cancer Wisconsin

3. Marketing y Publicidad 📢

Aplicación: Predicción de respuesta a campañas publicitarias, segmentación de clientes.

Dataset: Bank Marketing Dataset, Online Shoppers Purchasing Intention



4. Industria de la Comida y Bebidas 🍔

Aplicación: Predicción de satisfacción del cliente, análisis de precios de menús, recomendación de restaurantes.

Dataset: Fast Food Nutrition Dataset, Yelp Reviews Dataset

5. Comercio Electrónico y Retail 🛒

Aplicación: Predicción de ventas, análisis de abandono de carrito, recomendaciones de productos.

Dataset: Online Retail Dataset, Instacart Market Basket Analysis

6. Energía y Medio Ambiente 🌿

Aplicación: Predicción de consumo energético, análisis de contaminación ambiental.

Dataset: Global Power Plant Database, Air Quality Data



7. Transporte y Logística 🚚

Aplicación: Optimización de rutas, predicción de retrasos en vuelos, análisis de tráfico.

Dataset: Flight Delay Dataset, NYC Taxi Trip Data

8. Educación 🎓

Aplicación: Predicción de rendimiento estudiantil, detección de abandono escolar.

Dataset: Student Performance Dataset, Open University Learning Analytics

9. Deportes y Entretenimiento 🏆 🎬

Aplicación: Predicción de resultados deportivos, análisis de audiencias, recomendación de películas.

Dataset: FIFA Player Dataset, MovieLens Ratings

10. Recursos Humanos y Reclutamiento 👤

Aplicación: Predicción de rotación de empleados, análisis de satisfacción laboral.

Dataset: HR Analytics Employee Attrition, Job Salaries Dataset

**TEMÁTICAS
RECOMENDADAS
POR SECTOR
CADA GRUPO
DEBE
SELECCIONAR
UN DATASET
ALINEADO CON
ESTAS
TEMÁTICAS.**

Sector	Temática específica	Ejemplo de Dataset
 Banca y Finanzas	Predicción de impago de préstamos o fraude	"Give Me Some Credit" (Kaggle), "Bank Marketing Dataset" (UCI)
 Salud y Medicina	Diagnóstico de enfermedades basado en características clínicas	"Heart Disease Dataset" (UCI), "Diabetes Dataset" (Kaggle)
 Marketing y Publicidad	Eficiencia de campañas de marketing y conversión de clientes	"Online Shoppers Purchasing Intention Dataset" (UCI)
 Comercio Electrónico	Análisis de abandono de carrito y recomendación de productos	"E-Commerce Dataset" (Kaggle), "Retail Rocket Dataset" (UCI)
 Energía y Medio Ambiente	Predicción de consumo energético o impacto ambiental	"Global Power Plant Database" (World Resources Institute)
 Transporte y Movilidad	Predicción de accidentes o congestión vehicular	"US Traffic Accidents Dataset" (Kaggle)
 Bienes Raíces	Predicción de precios de vivienda	"Ames Housing Dataset" (Kaggle), "Boston Housing Dataset" (UCI)
 Recursos Humanos	Predicción de renuncias y satisfacción laboral	"HR Analytics Dataset" (Kaggle)
 Educación	Factores que influyen en el rendimiento académico	"Student Performance Dataset" (UCI)
 Entretenimiento y Streaming	Predicción de popularidad de películas o música	"Netflix Movies Dataset" (Kaggle), "Spotify Dataset" (Kaggle)

Método para Seleccionar Datasets

Paso 1: Identificar el Problema del Sector

Cada grupo responde estas preguntas para **definir qué quieren analizar** dentro de su sector:

✓ **¿Cuál es el problema de negocio o científico?** (Ejemplo: en salud, predecir enfermedades con base en síntomas).

✓ **¿Qué variables serían necesarias para predecir el problema?** (Ejemplo: edad, IMC, nivel de colesterol).

✓ **¿Qué tipo de modelo se usará?** (Ejemplo: clasificación o regresión).

- **Ejemplo para Banca:**

Problema: ¿Un cliente pagará su préstamo?

Variables clave: Edad, ingresos, historial crediticio.

Modelo: Clasificación (sí/no).

Paso 2: Búsqueda de Datasets

Los estudiantes deben buscar datasets en fuentes confiables, como:

- ✓ **Kaggle** (<https://www.kaggle.com/datasets>)
- ✓ **UCI Machine Learning Repository**
(<https://archive.ics.uci.edu/ml/index.php>)
- ✓ **Google Dataset Search** (<https://datasetsearch.research.google.com/>)
- ✓ **DataHub.io** (<https://datahub.io/>)
- ✓ **Open Data de gobiernos** (Ejemplo: <https://data.gov/>)

Cada grupo elige **3 datasets potenciales** y los analiza.

Paso 3: Evaluación del Dataset

Cada grupo evalúa sus 3 opciones con una rúbrica de 5 criterios:

- ◆ **Decisión:**

- ✓ **Elegir el dataset con mayor puntaje.**

- ✓ Justificar en un documento su elección y cómo lo usarán.

Criterio	Explicación	Puntaje (1-5)
Tamaño del dataset	¿Tiene suficientes registros (mínimo 10,000 filas si es posible)?	
Variables útiles	¿Incluye las variables clave para el problema?	
Calidad de los datos	¿Hay datos faltantes, valores atípicos, errores?	
Accesibilidad	¿Es un dataset público y descargable?	
Formato y estructura	¿Está en CSV, JSON, o un formato fácil de procesar?	

Rúbrica de Evaluación de Datasets

Cada grupo debe evaluar **tres datasets** usando esta tabla. **El dataset con la puntuación más alta será el elegido.**

Criterio	Explicación	Puntuación (1-5)
1. Tamaño del dataset	Un dataset con más datos permite modelos más precisos y generalizables. Idealmente, debe tener al menos 10,000 filas (excepto en sectores con datos escasos, como salud).	1: Menos de 1,000 filas (insuficiente). 3: Entre 1,000 y 10,000 filas (acceptable). 5: Más de 10,000 filas (ideal).
2. Variables útiles	Debe incluir variables relevantes para el problema. Si faltan variables clave, el modelo será menos útil.	1: Solo tiene datos generales, sin variables clave. 3: Tiene algunas variables útiles, pero faltan otras. 5: Contiene todas las variables clave para el problema.
3. Calidad de los datos	Datos con muchos valores nulos o inconsistencias pueden ser problemáticos y requerir mucho preprocesamiento.	1: Datos muy sucios (muchos valores nulos, errores graves). 3: Datos con algunas inconsistencias manejables. 5: Datos bien estructurados y limpios.
4. Accesibilidad	Debe ser un dataset público y fácil de descargar. Si requiere permisos especiales o pagos, no es adecuado.	1: Privado, difícil de acceder. 3: Requiere registro o limpieza extensa antes de usar. 5: Disponible públicamente y fácil de descargar.
5. Formato y estructura	Debe estar en un formato usable como CSV, JSON, SQL y bien organizado (sin columnas ambiguas).	1: Formato difícil de usar (PDF, imágenes, texto sin estructura). 3: CSV o JSON pero con problemas en los nombres de columnas o estructura. 5: CSV, JSON o SQL bien estructurado.

Ejemplo

Criterio	Dataset 1 (Bank Loan Defaults)	Dataset 2 (Bank Marketing)	Dataset 3 (Credit Risk)
Tamaño	50,000 filas (5)	45,000 filas (5)	5,000 filas (3)
Variables útiles	Tiene historial de crédito, ingresos, edad (5)	Solo datos demográficos (3)	Solo monto del préstamo y decisión final (2)
Calidad de los datos	Tiene valores nulos en ingresos (3)	Bien estructurado (5)	Muchos valores faltantes (2)
Accesibilidad	Público, en Kaggle (5)	Público, en UCI (5)	Requiere solicitud de acceso (1)
Formato y estructura	CSV bien estructurado (5)	CSV bien organizado (5)	Formato extraño, con nombres de columnas poco claros (2)
TOTAL	23/25  (Elegido)	23/25  (Elegido)	10/25  (Descartado)

Supongamos que un grupo en el sector de **banca** busca un dataset para predecir impago de préstamos. Evaluaron 3 datasets y los calificaron así:

Decisión: Eligieron **Dataset 1** o **Dataset 2** porque son grandes, públicos y tienen las variables necesarias.

Parámetros para Formular Preguntas Críticas

Dimensión	¿Qué deben cuestionarse?	Ejemplo en el Refugio de Animales
1 Calidad de los datos	¿Los datos son representativos? ¿Hay sesgos o valores atípicos?	¿La edad promedio de los perros en el dataset representa bien a la población real del refugio?
2 Precisión del modelo	¿El modelo es fiable? ¿Cómo saber si los errores afectan las decisiones?	¿El modelo subestima el tiempo de adopción? ¿Qué impacto tiene esto en la planificación del refugio?
3 Interpretación y utilidad	¿Cómo se usan los resultados para mejorar el proceso?	Si los perros pequeños se adoptan más rápido, ¿qué estrategia debería tomar el refugio?

Preguntas sobre los datos

- 1 ¿Nuestros datos reflejan la realidad de nuestro sector o tienen sesgos?
- 2 ¿Qué variables podrían estar afectando el problema y no las estamos considerando?
- 3 ¿Cómo podemos mejorar la calidad de nuestros datos para tener modelos más precisos?

Ejemplo en Salud:

¿Los datos de pacientes representan a toda la población o solo a un grupo específico?



Preguntas sobre el modelo

- 4 ¿Cómo sabemos si nuestro modelo es bueno o si estamos sobreajustando/subajustando?
- 5 ¿Cuál es el impacto de un mal modelo en las decisiones reales de la empresa o sector?
- 6 ¿Cómo podemos mejorar la precisión del modelo sin perder interpretabilidad?
- **Ejemplo en Banca:**
Si nuestro modelo predice mal el riesgo crediticio, ¿estamos rechazando clientes buenos?

Preguntas sobre la interpretación y uso del modelo

- 7 ¿Qué decisiones tomaríamos en la empresa o sector con los resultados del modelo?
- 8 Si los resultados del modelo son inesperados, ¿cómo podemos justificarlo o corregirlo?
- 9 ¿Nuestro modelo ayuda a tomar mejores decisiones o es solo un ejercicio teórico?
- **Ejemplo en Marketing:**
Si encontramos que las mujeres compran más cierto producto, ¿es un sesgo en los datos o una tendencia real? ¿Cómo usaríamos esto sin caer en malas prácticas?

¡MUCHAS GRACIAS!

