

The background features three vertical stripes on the left side: a wide pink stripe, a medium blue stripe, and a narrow light beige stripe. The rest of the background is a light beige color with two rectangular areas of small, light pink dots in the top right and bottom right corners.

PARCIAL MARKETING DIGITAL

Alan Osorio - Daniela Lopez - Ana Amador

Diseño de estrategia de negocio basada en clusters

1

Naming automático (reglas de negocio)

	n	Nombre	Impressions	Clicks	Spent	CTR	CPC	CVR	ApprovedConv	CPA
cluster										
0	753	C1 – Consideración rentable	96959.03	16.77	25.84	0.000173	1.540847	3.458557e-02	0.58	4.455172e+01
1	130	C0 – Awareness eficiente	694644.42	129.55	197.64	0.000186	1.525589	1.868005e-02	2.42	8.166942e+01
2	140	C2 – Performance premium	2617.98	0.03	0.01	0.000011	0.333333	3.333333e-01	0.01	9.999999e-01
3	26	C1 – Consideración rentable	1301029.42	192.92	316.24	0.000148	1.639229	4.965789e-02	9.58	3.301044e+01
4	71	C2 – Performance premium	2209.94	0.00	0.00	0.000000	0.000000	1.070000e+09	1.07	0.000000e+00
5	23	C0 – Awareness eficiente	685683.22	159.74	231.62	0.000233	1.449981	0.000000e+00	0.00	2.316200e+11

Se aplicó K-Means para agrupar las campañas publicitarias según su rendimiento, analizando métricas como tasa de clics, costo por clics, tasa de conversión y costo por acción. Los resultados muestran tres perfiles principales de desempeño y algunos grupos con datos poco confiables:

1. **Consideración rentable (Clusters 0 y 3)**

- Buena relación costo-beneficio.
- CTR y CPC equilibrados, con conversiones altas (CVR 3–5%) y CPA bajo (\$33–\$45).
- Representan las campañas más efectivas en términos de inversión y resultados.

2. **Awareness eficiente (Clusters 1 y 5)**

- Buscan visibilidad más que conversiones.
- Tienen CTR aceptable pero baja conversión (CVR <2%), lo que eleva el CPA (\$80 o más).
- En general, gastan más por resultado obtenido.

3. **Performance premium (Clusters 2 y 4)**

- Datos poco confiables o sin gasto real.
- En el cluster 2 hay muy pocos registros válidos, y en el 4 no hay clics ni inversión (errores por división entre cero).
- No se deben usar para decisiones.

Los mejores grupos son los de “Consideración rentable”, que logran mayor eficiencia en inversión y conversión. Las campañas tipo “Awareness” sirven para reconocimiento de marca, pero no para resultados directos. Los grupos con datos vacíos o distorsionados deben descartarse del análisis.

Acciones concretas por tipo de campaña

1

Cluster 1

Awareness eficiente

Campañas para generar alcance y clics.

- Se recomienda usar videos cortos y mensajes llamativos, probar varias piezas y eliminar las menos efectivas.
- No deben entrar en remarketing, para evitar gastar doble presupuesto en los mismos usuarios.

Clusters 2 y 4

Performance premium (experimentales)

Tienen datos poco confiables.

- Primero se debe auditar el seguimiento (tracking) y probar con pequeños presupuestos de test.
- Solo si logran al menos 30 clics válidos, se pueden escalar y mantener los anuncios ganadores en horarios y ubicaciones específicas.

Clusters 0 y 3

Consideración rentable

Son las más productivas.

- Se deben hacer pruebas A/B (texto, velocidad, formulario) para mejorar conversiones.
- Usar pujas por costo objetivo (CPA o CPC) para mantener estabilidad y escalar de forma controlada.
- Conviene trasladar un 20–30% del presupuesto desde las campañas ineficientes (clusters 1 y 5) hacia estos grupos, priorizando el cluster 3, que tiene el mejor costo por acción (\$33).

Cluster 5


Ineficiente o derrochador

Tiene conversiones nulas (CVR = 0).

- Debe pausarse y mover el presupuesto hacia campañas más efectivas.
- Si se vuelve a probar, hacerlo solo por 7 días y detener si no mejora el CPA.
- Revisar la coherencia entre el mensaje y el público objetivo; si sigue sin funcionar, eliminarlo definitivamente.

Prototipo de dashboard para toma de decisiones

2



Métricas clave del dashboard

- Impressions: muestran el alcance total de los anuncios.
- Clicks: indican cuántas personas interactuaron.
- Approved Conversions: reflejan las acciones válidas logradas (compras, registros, etc.).
- Spend (\$): gasto total invertido.

Ratios de rendimiento:

- $CTR = Clicks / Impressions$ → mide el interés.
- $CPC = Spend / Clicks$ → costo por clic.
- $CVR = Conversions / Clicks$ → efectividad del anuncio.
- $CPA = Spend / Conversions$ → costo por resultado.

Mix por clúster

Se muestra el porcentaje de presupuesto y de conversiones por clúster, permitiendo ver cuáles grupos son más eficientes.

Así se detecta fácilmente si el dinero está bien distribuido o si hay campañas que gastan mucho sin generar resultados.

Cómo este dashboard acelera decisiones:

- **Priorización visual:** el gráfico CPC vs CVR permite identificar de inmediato los clústeres más rentables (CVR alto, CPC bajo) y los menos eficientes.
- **Acción inmediata:** el panel de alertas convierte los datos en recomendaciones directas (por ejemplo, “escalar +15%” o “pausar campaña”).
- **Visión de impacto:** las barras apiladas de gasto vs conversiones muestran si el presupuesto actual se asigna a los clústeres que realmente convierten.
- **Control de eficiencia:** las tarjetas resumen de CPA promedio, gasto y conversiones dan una vista general para evaluar si se cumplen los objetivos.
- **Seguimiento operativo:** la tabla táctica con CTR, CPC, CVR y CPA por clúster permite decidir rápidamente qué campañas escalar, optimizar o pausar.

Clustering + predicción futura

1

Primero, entrenamos un modelo estable de clasificación utilizando Regresión Logística para predecir la probabilidad de conversión.

Usamos variables clave como CTR, CPC, logClicks, logSpend y el cluster_id.

Después de limpiar y escalar los datos, el modelo alcanzó un ROC-AUC de 0.836 con 1,143 registros.

Esto indica una excelente capacidad para distinguir entre campañas que convierten y las que no.

Este modelo sirve como base para las predicciones y recomendaciones interactivas del siguiente bloque.

```
# P3-A – Modelo estable (sin recargar datos ni re-clusterizar)
import numpy as np, pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import roc_auc_score

assert 'df' in globals(), "Falta df (de la Parte 1)."
assert 'cluster' in df.columns, "Falta df['cluster'] (de la Parte 1)."

eps = 1e-9
dfm2 = df[['Impressions', 'Clicks', 'Spent', 'Approved_Conversion', 'cluster']].replace([np.inf, -np.inf], np.nan).dropna().copy()
dfm2['CTR'] = dfm2['Clicks'] / (dfm2['Impressions'] + eps)
dfm2['CPC'] = dfm2['Spent'] / (dfm2['Clicks'] + eps)
dfm2['logClicks'] = np.log1p(dfm2['Clicks'])
dfm2['logSpend'] = np.log1p(dfm2['Spent'])
dfm2['y'] = (dfm2['Approved_Conversion'] > 0).astype(int)

feat_stable = ['CTR', 'CPC', 'logClicks', 'logSpend']
X = pd.get_dummies(pd.concat([dfm2[feat_stable], dfm2[['cluster']], axis=1),
                           columns=['cluster'], drop_first=True)
y = dfm2['y'].values

Xtr, Xte, ytr, yte = train_test_split(X, y, test_size=0.25, random_state=42, stratify=y)
sc_model = StandardScaler().fit(Xtr)
logc = LogisticRegression(max_iter=500, C=1.0).fit(sc_model.transform(Xtr), ytr)

auc = roc_auc_score(yte, logc.predict_proba(sc_model.transform(Xte))[:, 1])
feat_cols_model = X.columns.tolist()

print(f"✅ Modelo estable listo. ROC-AUC={auc:.3f} | filas={len(dfm2)}")

# HOTFIX – cuantiles para clipping (1-99%) y metas (25-75%)
q_clip = dfm2[['Impressions', 'Clicks', 'Spent', 'CTR', 'CPC']].quantile([0.01, 0.99])
q_meta = dfm2[['CTR', 'CPC']].quantile([0.25, 0.75])

✅ Modelo estable listo. ROC-AUC=0.836 | filas=1143
```

Clustering + predicción futura

2

Módulo interactivo de predicción que permite evaluar el rendimiento de un anuncio en tiempo real. A partir de los datos disponibles —Impressions, Clicks y Spend—, el sistema calcula dos métricas clave:

- CTR (Tasa de clic): mide el interés y la calidad del anuncio,
- CPC (Costo por Clic): refleja la eficiencia de la puja y la relevancia del público.

Con estos valores, el módulo asigna el anuncio a un clúster según su patrón de comportamiento y utiliza el modelo entrenado para estimar la probabilidad de conversión (P).

A partir de un umbral configurable, el sistema traduce esa probabilidad en una acción operativa:

- Si P es alta, recomienda ESCALAR la campaña.
- Si P es baja, sugiere OPTIMIZAR o PAUSAR, mostrando además recomendaciones específicas para mejorar CTR o reducir CPC.

The screenshot shows a dark-themed interface for an interactive prediction module. At the top, there are three input fields: 'Impressions' with the value '30000', 'Clicks' with '210', and 'Spend' with '180'. Below these is a slider for 'Umbral P' set to '0.60'. A blue button labeled 'Predecir' is positioned below the slider. The results section displays: 'Prob. de conversión (P): 0.448', 'Acción sugerida: OPTIMIZAR/PAUSAR', and a detailed status line: 'cluster=4 | CTR=0.007000 | CPC=0.86 | Umbral=0.60'. At the bottom, a recommendation message reads: '¿Qué mejorar para alcanzar el umbral? → Acción: OPTIMIZAR (aplica las mejoras arriba) y reevalúa en 48–72h.'

Ejemplo 1 (bueno):

Impressions = 30,000 | Clicks = 210 (CTR = 0.7%)
| Spend = 180 (CPC = 0.86) | Umbral = 0.60 →
Probabilidad alta ⇒ OPTIMIZAR (aplica las mejoras arriba) y reevalúa en 48–72h.

Simulación de impacto de los clusters en un caso real

Primero, construimos una base de simulación que toma los resultados del modelo estable y calcula, para cada clúster, los totales de gasto (Spend), conversiones (Conv), probabilidad media de conversión y CPA (costo por acción).

Con esta información, se implementó una función que simula mover una parte del presupuesto (por ejemplo, 20%) desde los clústeres menos eficientes —los que tienen probabilidad baja— hacia los más rentables, aplicando supuestos de elasticidad:

- si un clúster ganador recibe más inversión, sus conversiones aumentan proporcionalmente;
- si uno perdedor pierde presupuesto, sus conversiones disminuyen ligeramente.

El sistema compara los resultados antes y después del cambio, mostrando métricas clave como Spend total, Conversiones y CPA global, para analizar si la estrategia realmente mejora la eficiencia.

```
# P4-A – Base y simulación (usa dfm2 + modelo estable de la Parte 3)
import numpy as np, pandas as pd
from IPython.display import display, Markdown

# Probabilidad media por clúster con el modelo estable
def prob_media_por_cluster(dfm2, logc, sc_model, feat_cols_model):
    Xfull = pd.get_dummies(
        pd.concat([dfm2[['CTR', 'CPC', 'logClicks', 'logSpend']], dfm2[['cluster']], axis=1),
        columns=['cluster'], drop_first=True
    )
    for c in feat_cols_model:
        if c not in Xfull.columns:
            Xfull[c] = 0
    Xfull = Xfull[feat_cols_model]
    p = logc.predict_proba(sc_model.transform(Xfull))[:, 1]
    return pd.DataFrame({'cluster': dfm2['cluster'].values, 'prob': p}).groupby('cluster')['prob'].mean()

# Agregados base por clúster
probs = prob_media_por_cluster(dfm2, logc, sc_model, feat_cols_model)

base = dfm2.groupby('cluster').agg(
    spend=('Spend', 'sum'),
    conv=('Approved_Conversion', 'sum'),
    filas=('cluster', 'size')
).astype(float)

base['prob_media'] = probs
base['CPA'] = np.where(base['conv'] > 0, base['spend'] / base['conv'], np.inf)

# Simulación: mover % del gasto de perdedores a ganadores con elasticidades
def simular(base, p_umbral=0.60, move_pct=0.20, elas_up=0.70, elas_down=0.50):
    base = base.copy()

    gan = base[base['prob_media'] >= p_umbral]
    per = base[base['prob_media'] < p_umbral]

    monto_mover = (per['spend'] * move_pct).sum()
    asign = (gan['prob_media'] / gan['prob_media'].sum()) * monto_mover if len(gan) > 0 else pd.Series(dtype=float)

    after = base.copy()
    # Restar a perdedores
    for c in per.index:
        delta = base.loc[c, 'spend'] * move_pct
        after.loc[c, 'spend'] -= delta
        after.loc[c, 'conv'] *= (1 - elas_down * move_pct)

    # Sumar a ganadores (distribución proporcional a prob_media)
    for c in asign.index:
        added = asign.loc[c]
        pct = added / base.loc[c, 'spend'] if base.loc[c, 'spend'] > 0 else 0.0
        after.loc[c, 'spend'] += added
        after.loc[c, 'conv'] *= (1 + elas_up * pct)

    after['CPA'] = np.where(after['conv'] > 0, after['spend'] / after['conv'], np.inf)

    tot0 = (base['spend'].sum(), base['conv'].sum(), base['spend'].sum() / base['conv'].sum())
    tot1 = (after['spend'].sum(), after['conv'].sum(), after['spend'].sum() / after['conv'].sum())

    return base, after, asign, tot0, tot1

print("✅ Base lista para simulación interactiva (usa modelo estable y dfm2).")
```

Simulación de impacto de los clusters en un caso real

4

```
# P4-B - Simulación interactiva con sliders
import ipywidgets as w
from IPython.display import display, Markdown

p_umbral = w.FloatSlider(value=0.60, min=0.30, max=0.90, step=0.05, description='P_ganador', readout_format='.2f')
move_pct = w.FloatSlider(value=0.20, min=0.05, max=0.50, step=0.05, description='Reasignar %', readout_format='.2f')
elas_up = w.FloatSlider(value=0.70, min=0.10, max=1.00, step=0.05, description='Elasticidad +', readout_format='.2f')
elas_dn = w.FloatSlider(value=0.50, min=0.10, max=1.00, step=0.05, description='Elasticidad -', readout_format='.2f')

btn = w.Button(description='Simular', button_style='primary')
out = w.Output()

def on_sim(_):
    with out:
        out.clear_output()
        b, a, asign, tot0, tot1 = simular(base, p_umbral.value, move_pct.value, elas_up.value, elas_dn.value)
        S0, C0, CPA0 = tot0
        S1, C1, CPA1 = tot1
        dC, dCPA = C1 - C0, CPA1 - CPA0

        display(Markdown(f"""ANTES** → Spend={S0:.2f} | Conversions={C0:.2f} | CPA={CPA0:.2f}"""))
        display(Markdown(f"""DESPUÉS** → Spend={S1:.2f} | Conversions={C1:.2f} | CPA={CPA1:.2f}"""))
        display(Markdown(f"""Cambios** → ΔConversions = {dC:+.2f} | ΔCPA = {dCPA:+.2f} *(negativo = mejora)"""))

        display(Markdown("""Asignación a ganadores (USD):"""))
        display(asign.to_frame('delta_spend_ganador').round(2))

        display(Markdown("""Detalle ANTES (por clúster):"""))
        display(b.round(3))

        display(Markdown("""Detalle DESPUÉS (por clúster):"""))
        display(a.round(3))

btn.on_click(on_sim)
display(w.VBox([w.HBox([p_umbral, move_pct]), w.HBox([elas_up, elas_dn]), btn, out]))
```

Implementamos una simulación interactiva “antes vs. después” para analizar el impacto de reasignar presupuesto entre clústeres.

A partir de los datos históricos, el sistema calcula por clúster el gasto (Spend), las conversiones (Conversions), el CPA y la probabilidad media de conversión estimada por el modelo anterior.


El usuario puede ajustar tres parámetros: P_ganador (umbral que define los clústeres más rentables), % de reasignación (presupuesto transferido de perdedores a ganadores) y elasticidades (cómo varían las conversiones al subir o bajar la inversión).

Con estos supuestos, el sistema redistribuye el gasto, recalcula conversiones y CPA, y muestra un comparativo ANTES vs. DESPUÉS, junto con la nueva asignación a los ganadores.

De esta forma, el módulo demuestra cómo una estrategia basada en clústeres puede aumentar conversiones o reducir el CPA sin incrementar el presupuesto total.

Simulación de impacto de los clusters en un caso real

4



- P_ganador: desde qué probabilidad un clúster cuenta como “ganador”.
- Reasignar %: qué % del presupuesto se mueve de perdedores → ganadores.
- Elasticidad +: cuánto suben las conversiones cuando le subo presupuesto a ganadores.
- Elasticidad -: cuánto bajan las conversiones cuando le quito presupuesto a perdedores.

Qué hace:

- Identifica ganadores ($P \geq P_{\text{ganador}}$) y perdedores.
- Mueve el % elegido del gasto de perdedores a ganadores.
- Proyecta el efecto con las elasticidades y te muestra ANTES vs DESPUÉS (Conversions y CPA).
- “Si pongo P_ganador 0.60 y Reasignar 20%, el sistema mueve 20% del presupuesto hacia los clústeres con mejor probabilidad, estima el impacto y me muestra si suben las conversiones y baja el CPA.”

Cluster como base para un sistema de recomendación simple

Entradas:

- Datos del anuncio: Impressions, Clicks, Spend → base diaria de evaluación.

Métricas calculadas:


- $CTR = Clicks / Impressions$ (interés)
- $CPC = Spend / Clicks$ (costo)
- $logClicks / logSpend$ (normalización).

Guardrails (seguridad):


- Si $CTR < \text{mínimo}$ → optimizar antes de escalar.
- Si $CPC > \text{máximo}$ → reducir costo (relevancia, puja, exclusiones).

Asignación de clúster:

- Con KMeans “en vivo” se asigna el cluster_id (C0–C3) según el patrón de rendimiento.



Cluster como base para un sistema de recomendación simple



Predicción y decisión:

- Modelo de Regresión Logística estima P = probabilidad de conversión.
- Si $P \geq$ umbral y sin alertas $\rightarrow$ Escalar presupuesto (+10–20%).
- Si $P <$ umbral o hay alertas $\rightarrow$ Optimizar o Pausar.

Reglas rápidas por clúster:

- C0 Awareness: ampliar alcance, vigilar CPC.
- C1 Consideración: A/B creatividades, escalar gradual.
- C2 Performance: priorizar inversión, monitoreo diario.
- C3 Ineficiente: pausar y reasignar presupuesto.

Simulación de presupuesto:

- Reasigna gasto desde perdedores hacia ganadores y compara Conversions y CPA antes vs. después.

Feedback continuo:

- Medir resultados, ajustar umbral y reglas, y retroalimentar el sistema para el siguiente ciclo.

Reglas por clúster

Cluster 3 (Muy eficiente)	Cluster 1 (Eficiente)	Cluster 0 (Medio)	Cluster 2 (Bajo/anómalo)
Si $P \geq P_{\text{alta}}$ y $CPA \leq CPA_{\text{obj}}$ → ESCALAR +15–25%; duplicar mejores creatividades; whitelists.	Si $P \geq P_{\text{alta}}$ y $CPA > CPA_{\text{obj}}$ → OPTIMIZAR (cap de frecuencia, nuevos formatos, bajar CPC) y ESCALAR moderado +10% sólo si CPA baja una semana.	Si $0.40 \leq P < P_{\text{alta}}$ → MANTENER/OPTIMIZAR: A/B de creatividades y segmentación; si no mejora en 7 días → reasignar -10% a (3) y (1).	AUDITORÍA inmediata de tracking (tu “Spend≈0 con conv altas” es inconsistente). CAPEAR el gasto ($\leq 5\%$) hasta corregir; si se corrige y P sube → reevaluar.
Si $CPA > CPA_{\text{obj}}$ → OPTIMIZAR: bajar CPC (nuevos ganchos, tests de público), luego escalar.	Si $CPA \leq CPA_{\text{obj}}$ → ESCALAR +10–15%.	Si $P < 0.40$ o $CPA > CPA_{\text{obj}}$ → OPTIMIZAR o PAUSAR (según volumen).	

Convierten el análisis en acciones claras usando dos señales:

P (probabilidad de conversión del modelo) y CPA vs. objetivo.

- Si una campaña está en Cluster 3 (muy eficiente) y cumple P alta y $CPA \leq$ objetivo, se escala (+15–25%);
- si el CPA se dispara, primero se optimiza (bajar CPC) y luego se escala.
- En Cluster 1 (eficiente) se optimiza si el CPA está por encima y solo se escala moderado (+10–15%) si mejora;
- si ya está bajo objetivo, se escala directo.

- En Cluster 0 (medio) se mantiene/optimiza con A/B y segmentación;
- si no mejora en 7 días o $P < 0.40$, se pausa o reasigna presupuesto a 3 y 1. E
- En Cluster 2 (bajo/anómalo) se hace auditoría de tracking y se cappea el gasto hasta corregir. Así priorizamos inversión donde hay intención y eficiencia, y evitamos gastar en campañas caras o con baja probabilidad de convertir.

Aprendizaje de maquina | 2025

GRACIAS